

Predicción de posiciones en Fórmula 1 usando redes neuronales

Reporte técnico

Dataset: Formula 1 World Championship (1950–2024)

Modelo: Red neuronal artificial para regresión

Contenido del documento

- Introducción
- Dataset
- Metodología
- Preprocesamiento
- Modelo
- Resultados
- Referencias

.

Introducción

La Fórmula 1 es un deporte altamente basado en datos, donde el resultado de una carrera puede depender de factores como el piloto, el constructor, el circuito, la posición de salida y el contexto histórico de la temporada. Debido a esto, los datos de Fórmula 1 pueden utilizarse para resolver problemas de aprendizaje supervisado.

El objetivo de este proyecto es implementar un modelo para predecir la posición final de un piloto en una carrera de Fórmula 1. El proyecto toma como referencia metodológica el trabajo de O'Hanlon, donde se utilizan modelos de aprendizaje supervisado, incluyendo una red neuronal artificial, para predecir rankings de Fórmula 1.

Dataset

El dataset utilizado en este proyecto es *Formula 1 World Championship (1950–2024)*, disponible en Kaggle. Este conjunto de datos contiene información histórica de Fórmula 1 organizada en varios archivos CSV relacionados entre sí, incluyendo información de carreras, pilotos, constructores, circuitos y resultados.

Para este proyecto se seleccionaron únicamente los archivos más relevantes:

- `results.csv`: contiene los resultados de carrera, posición final, posición de salida, identificador del piloto e identificador del constructor.
- `aces.csv`: contiene información de cada carrera, como año, ronda e identificador del circuito.
- `drivers.csv`: contiene información de los pilotos.
- `constructors.csv`: contiene información de los constructores o equipos.
- `circuits.csv`: contiene información de los circuitos y países.

La variable objetivo seleccionada fue `positionOrder`, la cual representa la posición final obtenida por un piloto en una carrera. Debido a que esta variable es numérica, el problema se plantea como una tarea de regresión.

Las variables predictoras utilizadas en esta versión inicial fueron:

- `year`
- `round`
- `grid`
- `driverRef`
- `constructorRef`
- `circuitRef`
- `country`

Además, se filtraron únicamente datos desde el año 2010 en adelante. Esta decisión se tomó para reducir inconsistencias históricas relacionadas con cambios en reglamentos, sistemas de puntuación y formatos de competencia.

Metodología

Preprocesamiento


El preprocesamiento de los datos incluyó los siguientes pasos:

1. Carga de los archivos CSV seleccionados.
2. Selección de columnas relevantes en cada archivo.
3. Unión de los datasets mediante identificadores comunes como `raceId`, `driverId`, `constructorId` y `circuitId`.
4. Revisión de valores nulos.
5. Filtrado de datos desde el año 2010 en adelante.
6. Eliminación de registros donde la posición de salida (`grid`) era igual a cero.
7. Definición de `positionOrder` como variable objetivo.
8. Separación entre variables predictoras y variable objetivo.
9. Aplicación de **one-hot encoding** a variables categóricas.
10. Separación del dataset en conjuntos de entrenamiento y prueba.
11. Escalamiento de variables mediante `StandardScaler`.

Las variables categóricas, como piloto, constructor, circuito y país, fueron transformadas a formato numérico mediante *one-hot encoding*, ya que las redes neuronales no pueden trabajar directamente con texto.

El escalamiento fue aplicado porque las redes neuronales son sensibles a la escala de las variables de entrada. Al estandarizar los datos, se evita que variables con rangos numéricos más grandes tengan mayor peso durante el entrenamiento del modelo.

El dataset fue dividido en un conjunto de entrenamiento y un conjunto de prueba utilizando una proporción de 80% para entrenamiento y 20% para prueba.



Matriz de correlación de variables del dataset.

La matriz de correlación muestra que `grid` tiene una relación positiva con `positionOrder`, lo que indica que la posición de salida influye en la posición final de carrera. También se observa una relación negativa entre `points` y `positionOrder`, lo cual es esperado porque los pilotos que terminan en mejores posiciones reciben más puntos. Las variables como `raceId`, `driverId`, `constructorId` y `circuitId` son identificadores, por lo que sus correlaciones no deben interpretarse como relaciones causales.

Modelo

El modelo implementado en esta etapa es una red neuronal artificial básica. La arquitectura aún no está implementada con base en la configuración de hiperparámetros del paper.

La arquitectura general del modelo incluye:


- Una capa de entrada que recibe las variables preprocesadas.
- Capas densas ocultas con función de activación ReLU.
- Una capa de salida con una sola neurona y activación lineal.

La función de activación lineal en la capa de salida se utiliza porque el problema es de regresión. El modelo produce un valor numérico que representa la posición final estimada del piloto.

El modelo fue compilado con:

- Optimizador: Adam.
- Función de pérdida: Mean Squared Error.
- Métrica durante entrenamiento: Mean Absolute Error.


La función de pérdida Mean Squared Error fue seleccionada porque es común en problemas de regresión. La métrica Mean Absolute Error se utilizó porque permite interpretar el error de manera sencilla: indica, en promedio, por cuántas posiciones se equivoca el modelo.



Comportamiento de la pérdida en entrenamiento y validación.

La pérdida de entrenamiento y validación disminuye rápidamente durante las primeras épocas y después se estabiliza. Esto indica que el modelo aprende patrones relevantes del dataset. Además,

como la pérdida de validación no aumenta mientras la de entrenamiento disminuye, no se observa una señal fuerte de *overfitting*.



Comportamiento del MAE en entrenamiento y validación.

El MAE disminuye progresivamente tanto en entrenamiento como en validación, lo que muestra que el modelo mejora su capacidad de predicción con cada época. Al final, el error de validación se mantiene cercano al de entrenamiento, indicando una generalización aceptable para esta implementación inicial.

Resultados

La evaluación inicial del modelo se realizó utilizando métricas de regresión alineadas con el artículo base:

- Mean Absolute Error.
- Root Mean Squared Error.
- R^2 score.

Estas métricas son adecuadas porque el objetivo del modelo es predecir un valor numérico: la posición final de un piloto en carrera.

Los resultados iniciales obtenidos fueron:


Métrica	Resultado
MAE	1.55
RMSE	2.16
R^2	0.87

Resultados iniciales del modelo de regresión.

El MAE de 1.55 indica que, en promedio, el modelo se equivoca aproximadamente por 1.55 posiciones al predecir la posición final de un piloto. Por ejemplo, si un piloto termina en la posición 5, el modelo normalmente predice una posición cercana, con un error promedio de una a dos posiciones.


El RMSE de 2.16 indica que existen algunos errores más grandes, ya que esta métrica penaliza con mayor fuerza las predicciones alejadas del valor real. Sin embargo, considerando que una carrera de Fórmula 1 normalmente cuenta con alrededor de 20 pilotos, el error sigue siendo razonable para una implementación inicial.

El valor de R^2 de 0.87 sugiere que el modelo logra explicar aproximadamente el 87% de la variación en la variable objetivo. Esto indica que las variables seleccionadas contienen información útil para predecir la posición final, aunque todavía existe margen de mejora.



Comparación entre posiciones reales y predichas.

La gráfica muestra una tendencia positiva clara entre las posiciones reales y las predichas. La mayoría de los puntos se mantienen cerca de la línea diagonal, especialmente en posiciones delanteras y medias, lo que indica que el modelo predice de forma razonable. Sin embargo, existe mayor dispersión en posiciones más bajas, donde el modelo presenta más dificultad.



Resumen visual de las métricas del modelo.

La gráfica resume el desempeño inicial del modelo. El MAE de 1.55 indica un error promedio de aproximadamente una a dos posiciones, mientras que el RMSE de 2.16 muestra que existen algunos errores más grandes. El R^2 de 0.87 sugiere que el modelo explica una parte importante de la variación en la posición final.

Referencias

O'Hanlon, E. *Using Supervised Machine Learning to Predict the Final Rankings of the 2021 Formula One Championship*. National College of Ireland, 2022.

Kaggle. *Formula 1 World Championship (1950–2024)*.